

Ottimizzazione di un Sistema RAG

Progetto di Architetture Dati — A.A. 2025-2026

ANDREA MAURI · 945327

LUCA ROSSINI · 900230

FRANCESCO SORMANI · 894552

Introduzione

Il progetto ha come obiettivo la **creazione e ottimizzazione di un sistema RAG** (Retrieval-Augmented Generation).

Un sistema RAG combina il recupero di documenti rilevanti da una knowledge base con la generazione testuale di un LLM, fornendo risposte accurate e riducendo le **allucinazioni**.

01. Fase di Ottimizzazione

Test sistematici condotti per identificare la configurazione di recupero più precisa ed efficiente:

- Chunking & Embedding
- Query Transformation
- Retrieval e Reranking Neurale

02. Fase Generativa

Integrazione del sistema ottimizzato con modelli linguistici locali per la sintesi finale:

- Collegamento a 4 LLM locali (Ollama)
- 3 strategie di prompting
- Valutazione **LLM-as-a-Judge**

Architettura RAG

I componenti chiave dell'architettura di recupero includono strategie di segmentazione, rappresentazione vettoriale e meccanismi avanzati di query e selezione.

01. Chunking

Metodologie di scomposizione del testo:

- Token-based
- Sentence-based
- Semantic

02. Embedding

Modelli:

- all-MiniLM-L6-v2
- bge-base-en-v1.5
- bge-large-en-v1.5

03. Query Transf.

Riformulazione delle richieste:

- none
- HyDE
- Multi-Query
- RAG Fusion

04. Retrieval

Recupero e selezione finale:

- Vector Similarity
- Keyword Extraction
- Hybrid Search
- Reranking

Struttura e Tecnologie

Stack Tecnologico

LlamaIndex: framework per architetture RAG

Ollama & Groq: esecuzione locale LLM e API Groq a bassa latenza

Sentence-Transformers: embedding e reranking

PyMuPDF: estrazione testo da PDF

HuggingFace: download modelli open-source

Hardware

Blocco 1: Intel i7 9700K, 16GB RAM, RTX 2070 Super (8GB VRAM)

Blocchi 2–3 & Generativa: Ryzen 5700X, 32GB RAM, AMD RX 7600XT (16GB VRAM)

Domini Analizzati

RFC: Documenti tecnici su standard di rete

WW1: Testi storiografici narrativi sulla Grande Guerra

Workflow: Fase di Ottimizzazione

Tre blocchi sperimentali sequenziali, ciascuno con metriche di **DocRecall@k**, **PassageRecall@k**, **R-Precision, DocNDCG@k** e **PassageNDCG@k**.

01. Blocco 1

Configurazioni Core

- 7 configurazioni di **Chunking** ed **Embedding**
- Modelli **HuggingFace**

02. Blocco 2

Query Transformation

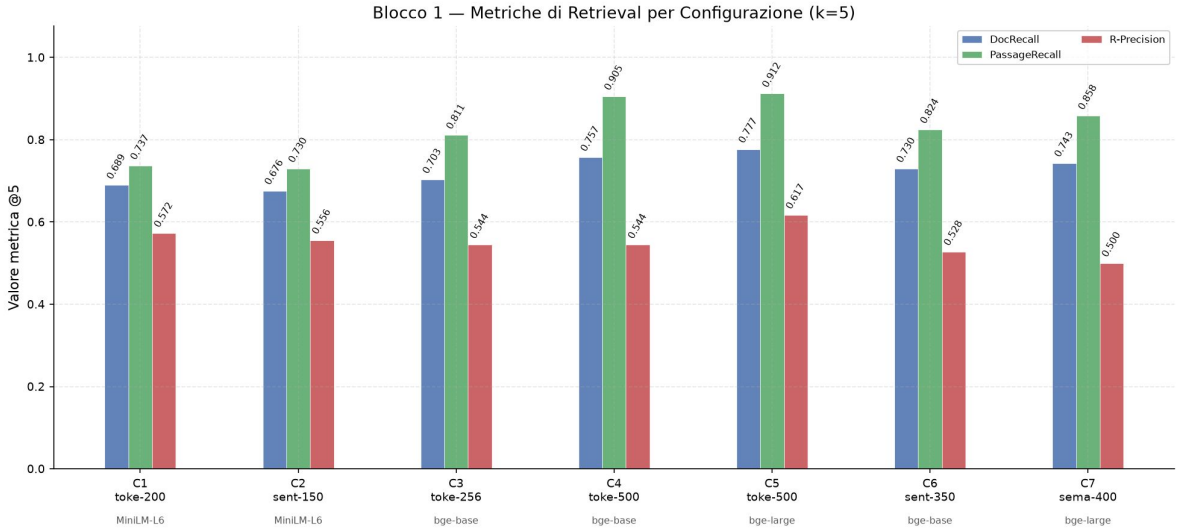
- 4 strategie analizzate
- Baseline, HyDE, Multi-Query, RAG Fusion
- API **Groq** (T=0.1)

03. Blocco 3

Retrieval & Reranking

- 7 configurazioni avanzate
- Vector, BM25, Hybrid Search
- **Cross-Encoder** (reranking k=10/20)

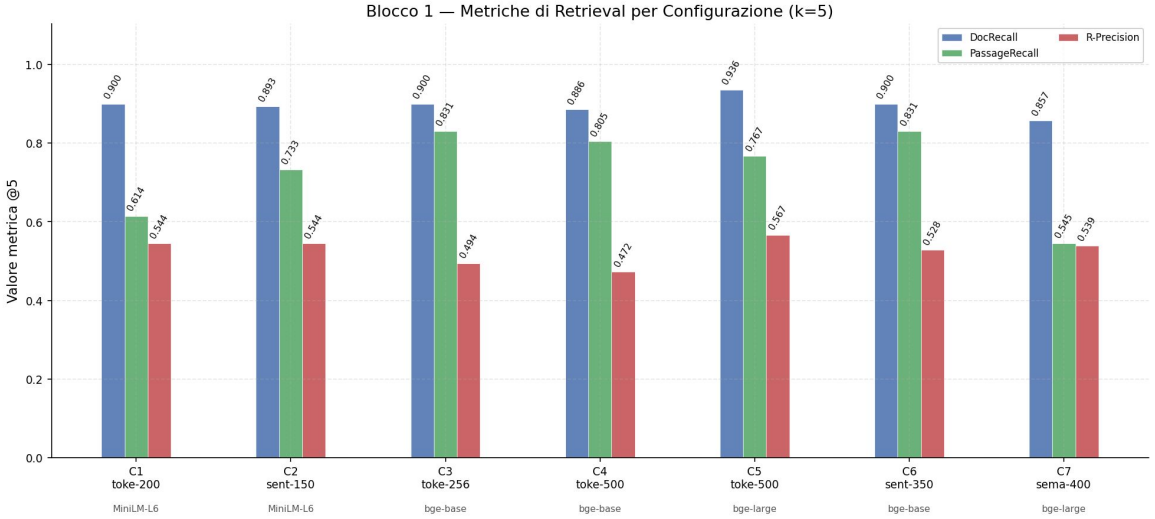
Risultati: Blocco 1 - Chunking ed Embedding

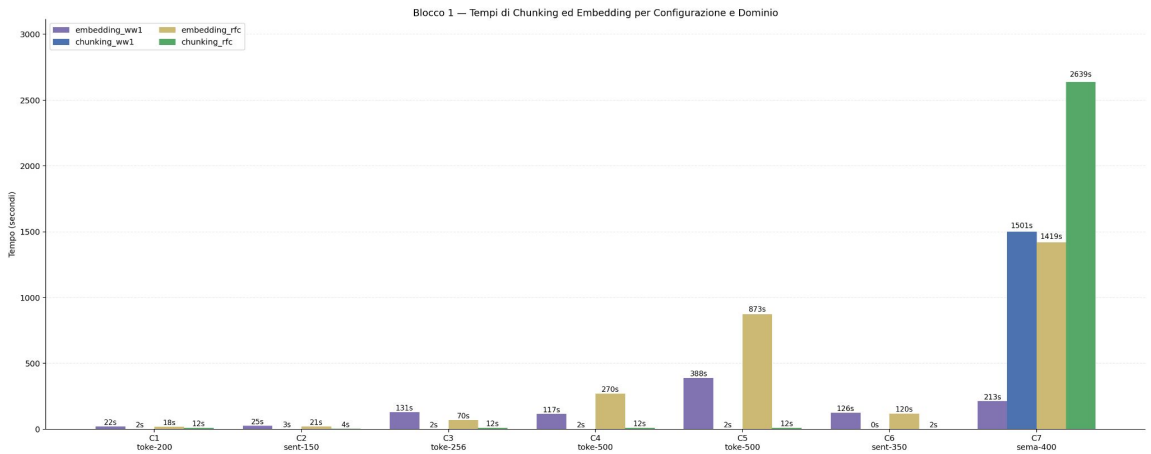


Vincitore: Configurazione C5

Medium-Chunk a 500 token con modello **bge-large-en-v1.5**.

- PassageRecall: **91%** (RFC), **94%** (WW1)
- DocRecall: **77.7%** (RFC), **94.9%** (WW1)
- R-Precision: **62%**(RFC), **57%** (WW1)
- **C7** (semantic) deludente: frammenta eccessivamente i testi narrativi
- L'indicizzazione è one-shot: il tempo maggiore di embedding è accettabile



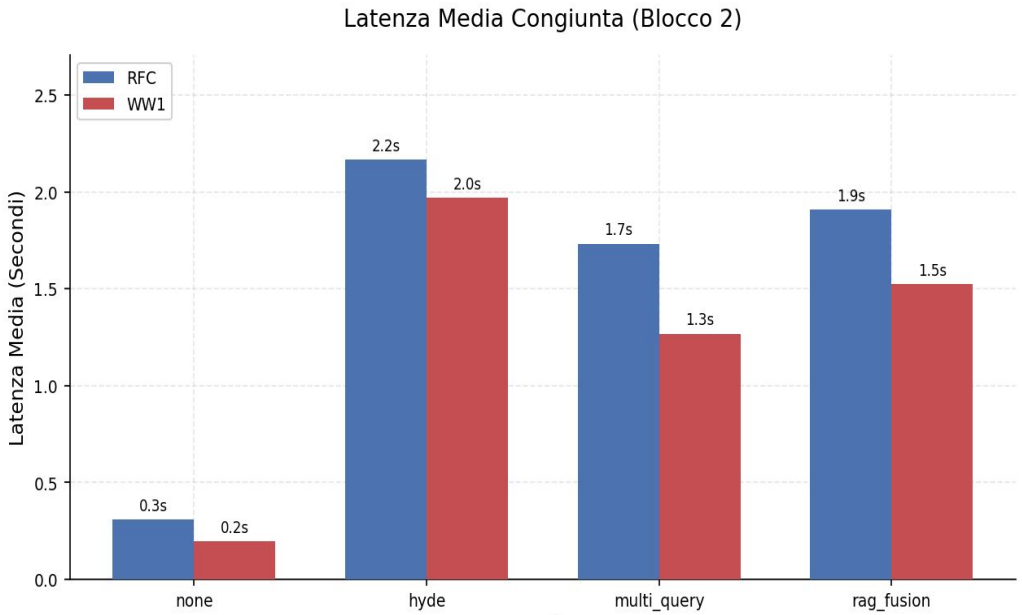


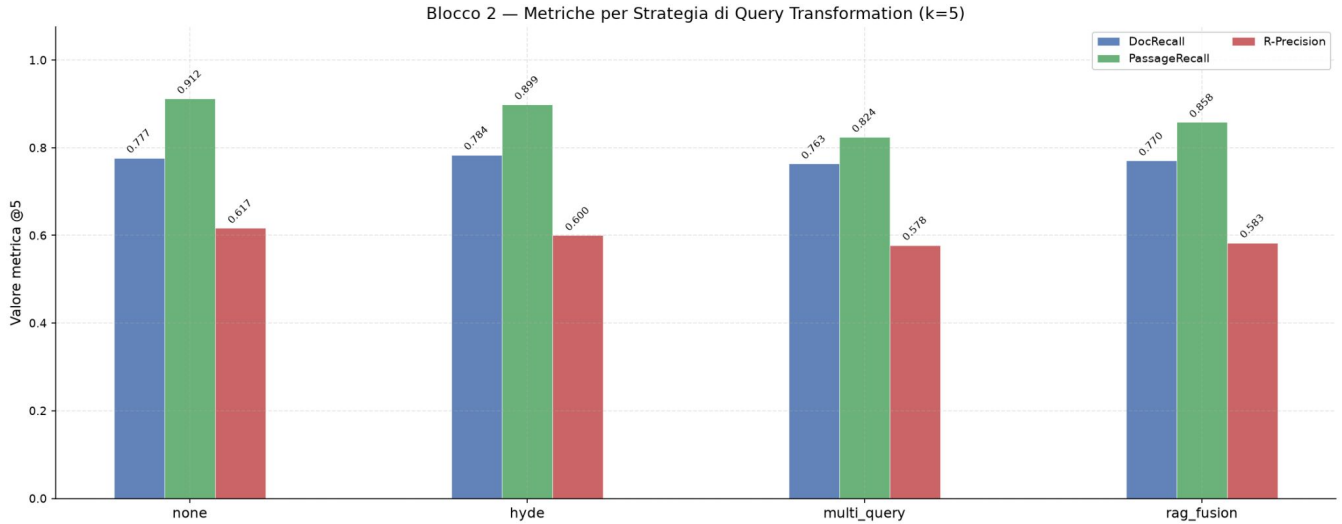
Risultati: Blocco 2 - Query Transformation

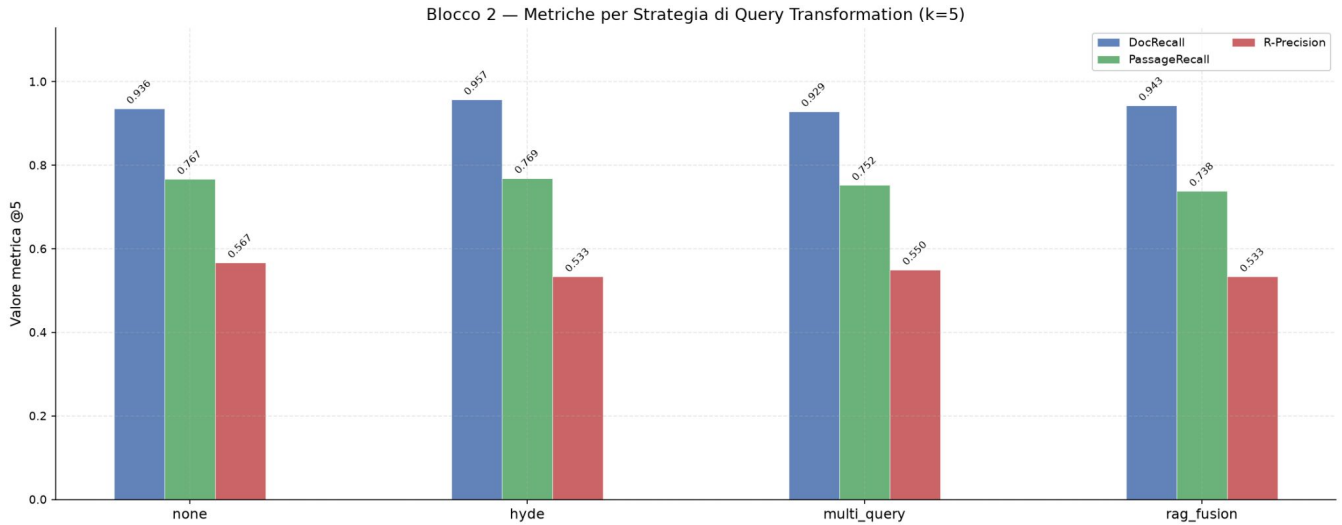
Vincitore: Baseline

La Baseline (nessuna trasformazione) ha eguagliato o superato le tecniche avanzate.

- HyDE, Multi-Query e RAG Fusion introducono rumore
- Baseline: latenza **0.3s**, 0 token consumati
- Query di tipo "noisy": ottimi risultati



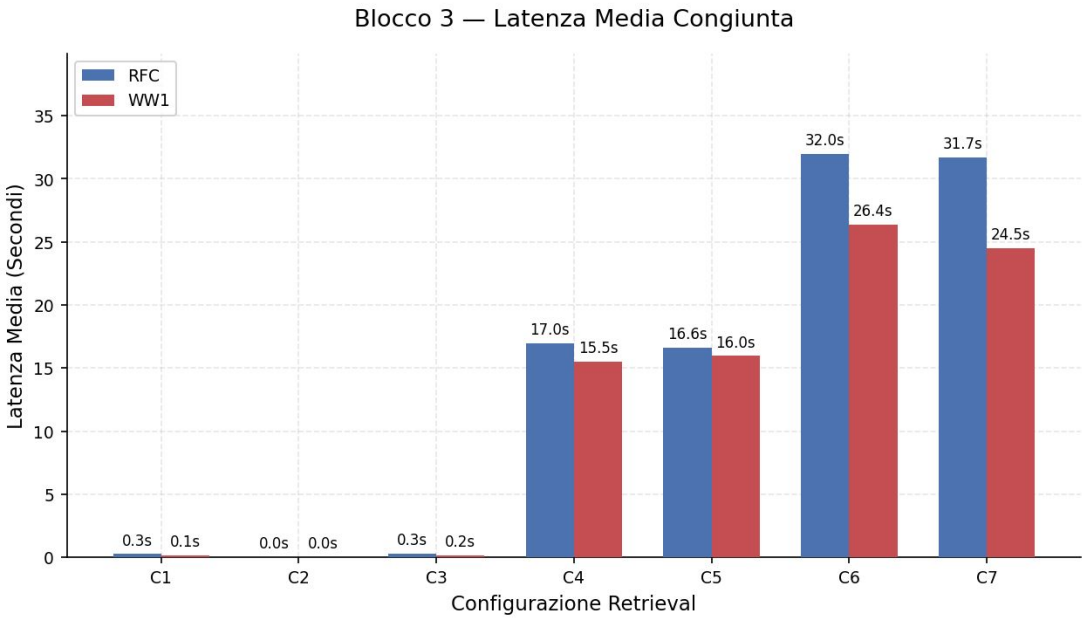


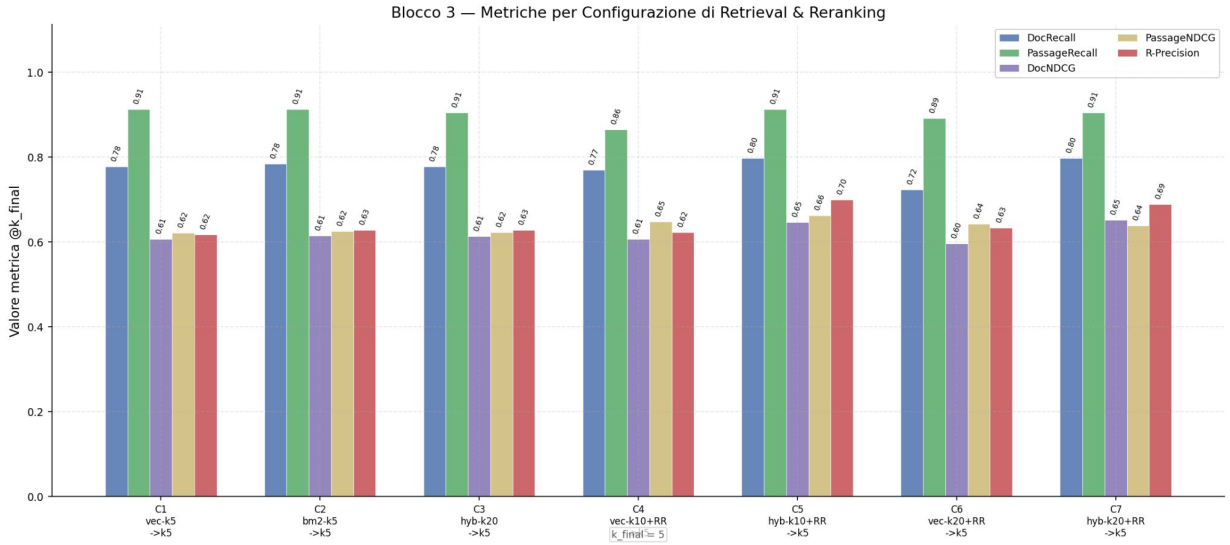


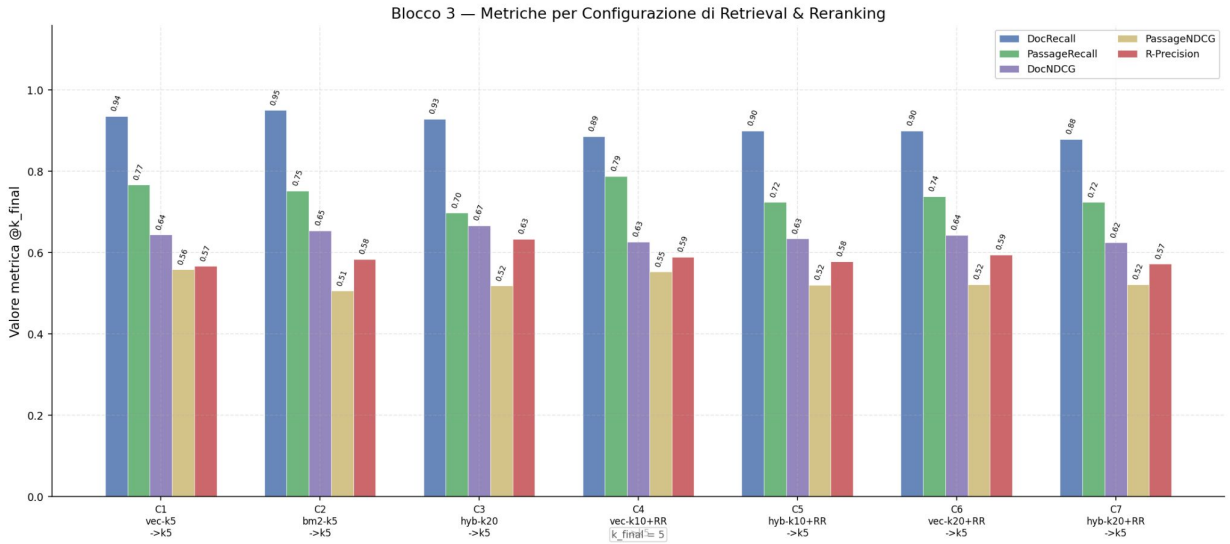
Risultati: Blocco 3 - Retrieval & Reranking

Vincitore: C2 (BM25 puro, k=5)

- DocRecall: **79%** (RFC), **95%** (WW1)
- PassageRecall: **78%** (RFC), **77%** (WW1)
- Latenza: **~0s** vs 17–32s delle config. con reranking
- Reranking: costo computazionale non giustificato dai guadagni







Fase Generativa: Setup Sperimentale

12 configurazioni combinate: 4 LLM locali (Ollama) × 3 strategie di prompting. Temperatura 0.0, approccio Zero-Shot.

Llama 3.2 (3B)

Modello ultraleggero Meta. Base per valutare le prestazioni minime.

Llama 3.1 (8B)

Modello standard di riferimento. Confronto diretto con la versione 3B.

Qwen 2.5 (7B)

Modello Alibaba. Eccellente reading comprehension (MMLU, IFEval).

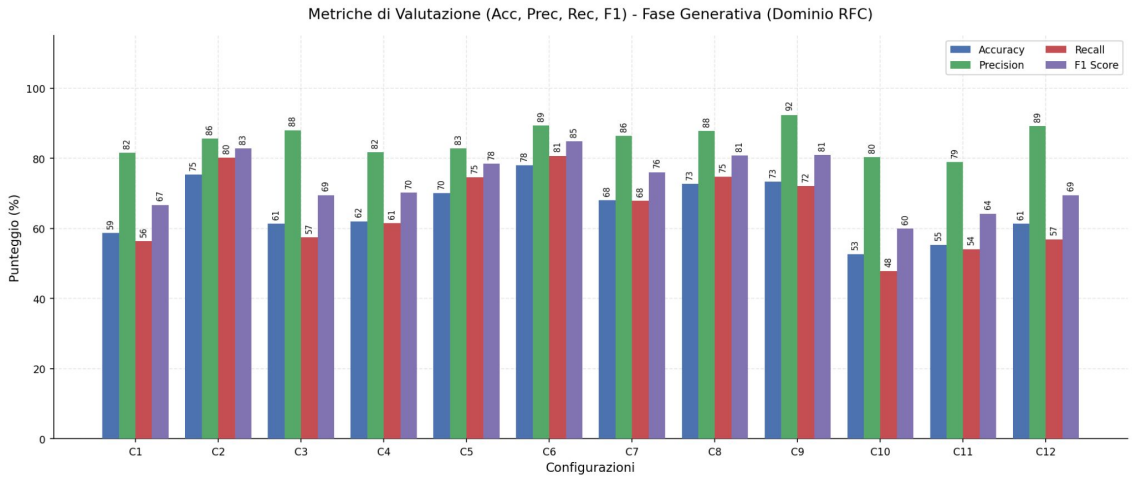
Gemma 2 (9B)

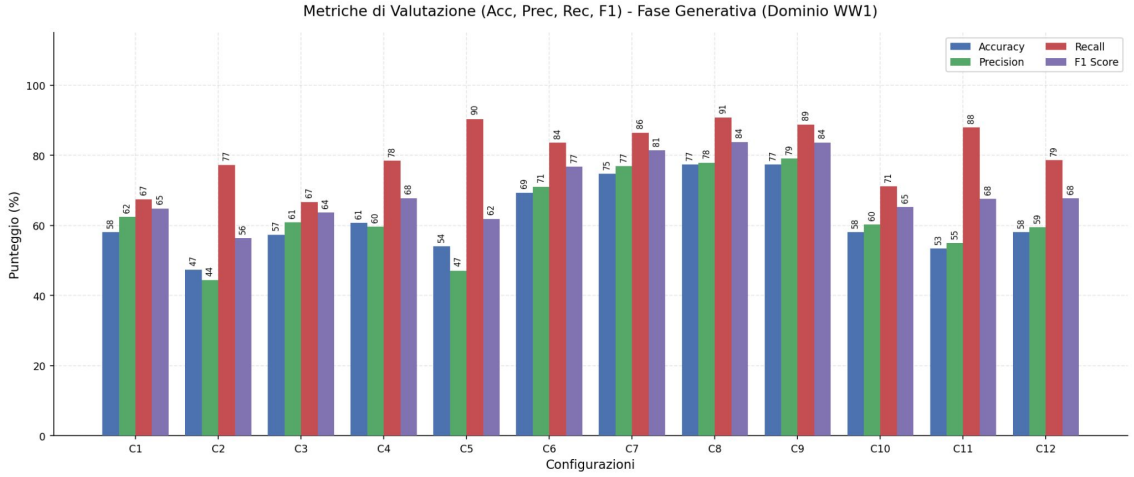
Modello Google, il più pesante. Termine di paragone per le massime prestazioni.

Strategie di Prompting

- Standard Prompt
- Step-Back Prompting
- Chain of Thought

Risultati: Fase Generativa





Dominio RFC — Vincitori: C2 e C6

Llama 3 (3B e 8B) con prompting avanzato eccellono grazie a doti **logico-analitiche**.

- F1: **88%** (C2) e **93%** (C6)
- Gemma 2 registra i punteggi più bassi

Dominio WW1 — Vincitori: C7, C8, C9

Qwen 2.5 7B domina indipendentemente dal prompt. F1: **82–85%**.

Superiorità in *reading comprehension* su testi narrativi.

I punteggi WW1 sono parzialmente distorti: il giudice valuta negativamente risposte lunghe con dettagli corretti ma anche dettagli superflui rispetto alla reference.

Conclusioni

I risultati ottenuti in questo studio dimostrano che l'efficienza di un sistema RAG dipende anche dal contesto operativo.

Configurazione Ottimale di Retrieval

Bilanciamento ideale tra accuratezza e latenza:

- **Chunk 500 token** + **bge-large-en-v1.5**
- Ricerca **BM25 pura** (senza trasformazioni o reranking)

LLM Vincitori per Dominio

RFC: Llama 3.2 3B con Step-Back Prompting (F1 88%).

WW1: Qwen 2.5 7B con Standard Prompt (F1 82–85%).

Riflessione

Per minimizzare le allucinazioni e massimizzare le prestazioni, è indispensabile calibrare le strategie di retrieval e la scelta dei LLM in base alle caratteristiche semantiche e strutturali dei dati.